Лексический анализ

1. Структура транслятора:

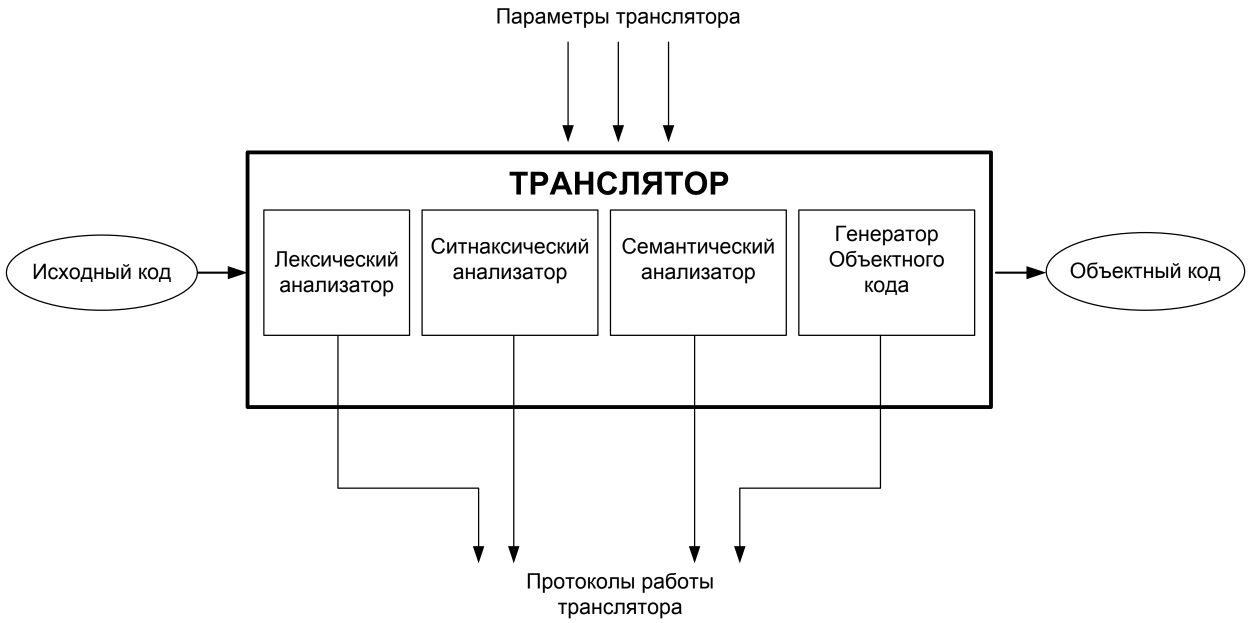

2. **Лексический анализ** – первая (наиболее простая) фаза трансляции. Лексический анализ выполняется программой (входящей в состав транслятора), называемой лексическим анализатором (или сканером).

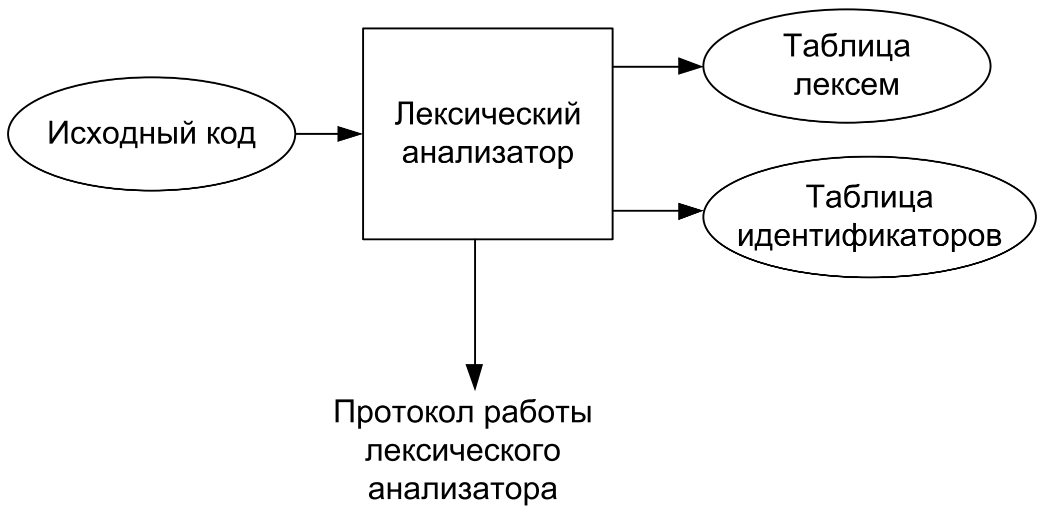

3. Взаимодействие лексического и синтаксического анализаторов:

последовательное

параллельное.

a) Последовательное взаимодействие лексического и синтаксического анализаторов.

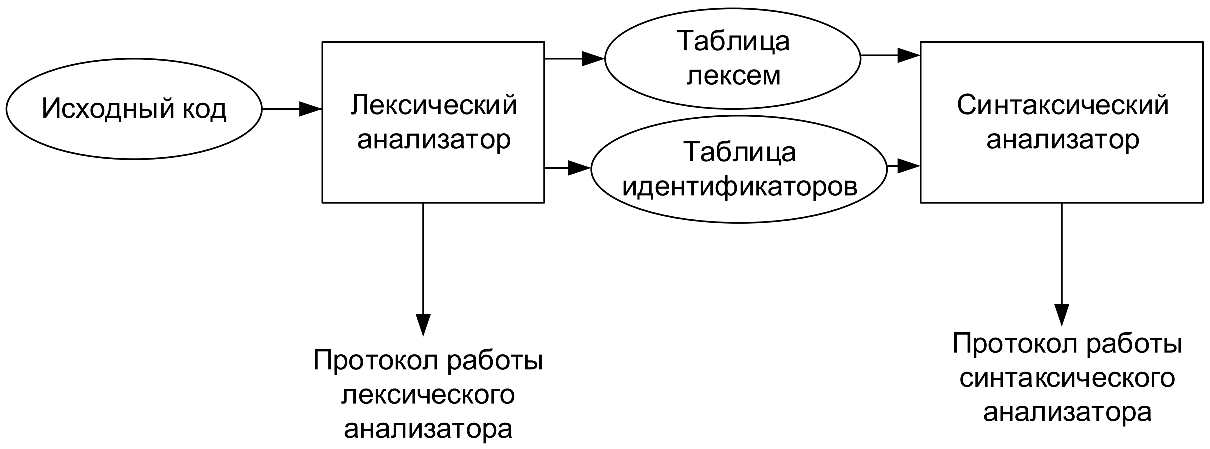

b) Параллельное взаимодействие лексического и синтаксического анализаторов.

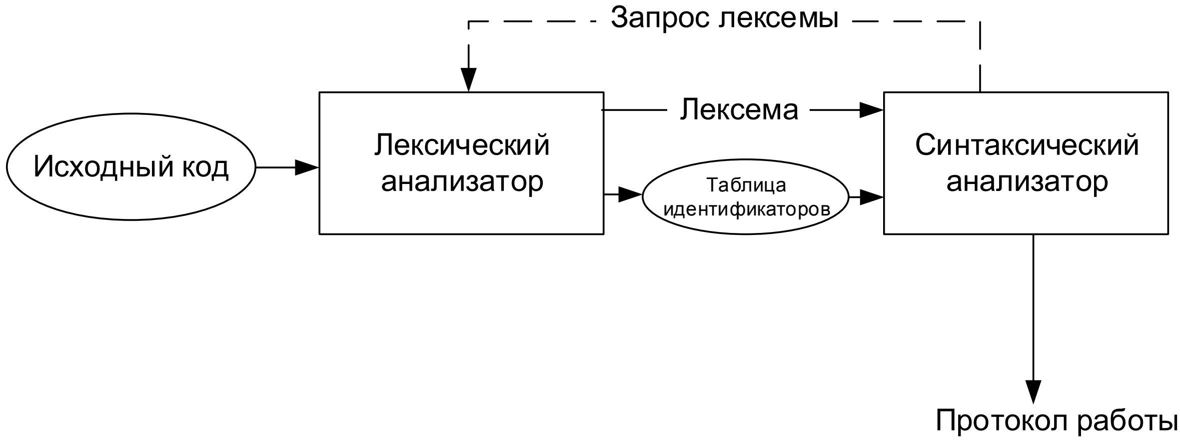

4. Пример:

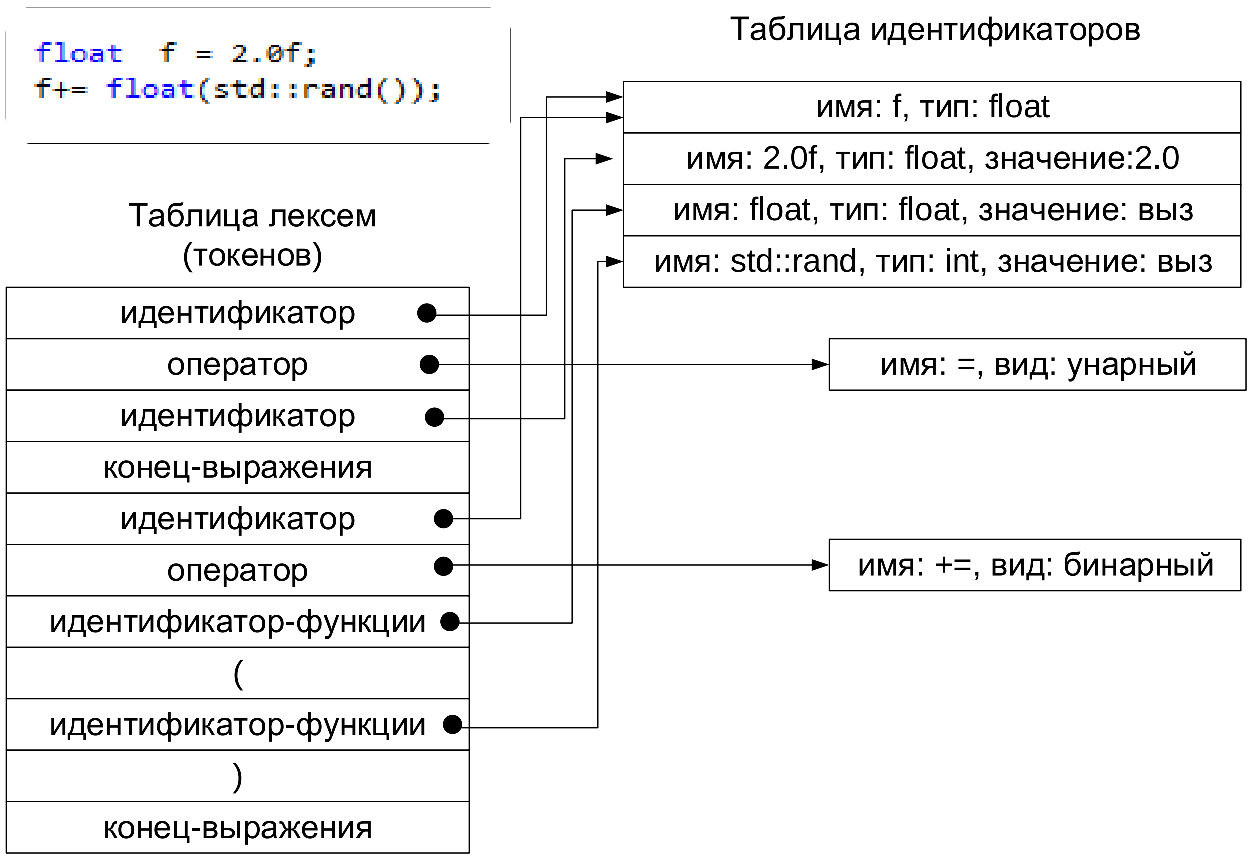

Взаимодействие лексического и синтаксического анализаторов C, C++, Java последовательное.

5. ***Примеры:***

a) грамматика $G = (T, N, P, S')$ для цепочки **float id**

$T = \{A, B, .., Z, a, b, ..., z, 0, 1, ...9, \omega, ;, =\}, N = \{S', A', B', C', D'\}$,

$S' \to floatA'$

$A' \to \omega B'$

$B' \to \omega B'$

$B' \to A \mid ... \mid Z \mid a \mid ... \mid z \mid AC' \mid ... \mid ZC' \mid aC' \mid ... \mid zC'$

$B' \to A \mid ... \mid Z \mid a \mid ... \mid z \mid AD' \mid ... \mid ZD' \mid aD' \mid ... \mid zD'$

$C' \to 0 \mid 1 \mid 2 \mid ... \mid 9 \mid 0C' \mid 1C' \mid 2C' \mid ... \mid 9C'$

$C' \to A \mid ... \mid Z \mid a \mid ... \mid z \mid AC' \mid ... \mid ZC' \mid aC' \mid ... \mid zC'$

$C' \to 0D' \mid 1D' \mid 2D' \mid ... \mid 9D'$

$C' \to AD' \mid ... \mid ZD' \mid aD' \mid ... \mid zD'$

$D' \to \omega D'$

$D' \to = \mid ;$

$\omega - пробел$

$G = (T, N, P, S')$ - регулярная ***праволинейная*** грамматика

b) ***Пример:*** вывод (распознавание) цепочки **float f;**

Вывод цепочки	Дерево нисходящего разбора цепочки
$S' \to floatA'$ $A' \to \omega B'$ $B' \to fD'$ $D' \to ;$	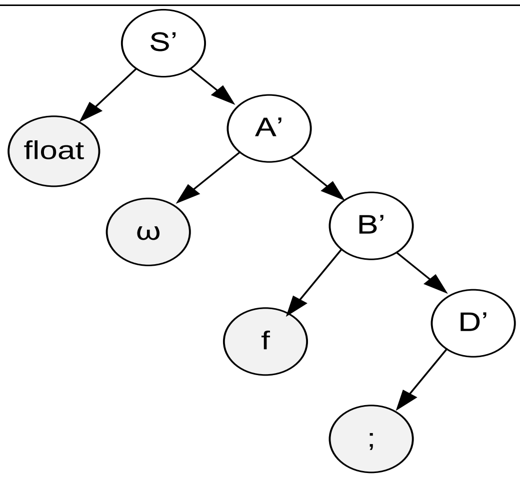

6. Примеры: правосторонний вывод.

Вывод называется ***правосторонним***, если в нем на каждом шаге вывода правило грамматики применяется всегда к крайнему правому нетерминальному символу в цепочке.

a) ***Пример:*** вывод (распознавание) цепочки **float f2x =**

Вывод цепочки	Дерево нисходящего разбора цепочки
$S' \to floatA'$ $A' \to \omega B'$ $B' \to fC'$ $C' \to 2C'$ $C' \to xD'$ $D' \to \omega D'$ $D' \to =$	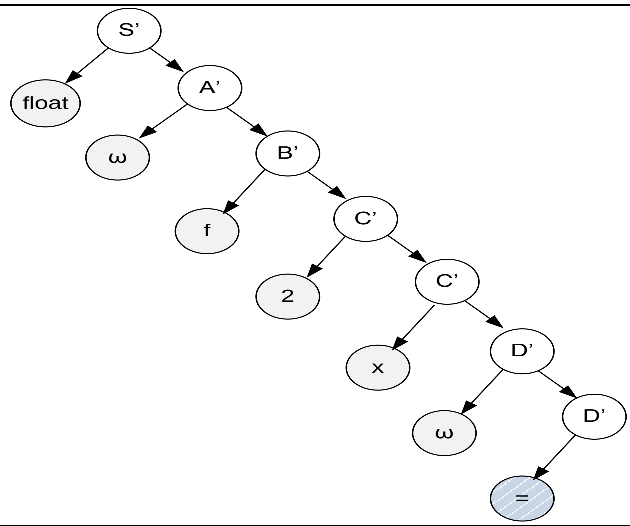

b) ***Пример:*** вывод (распознавание) цепочки **float 22x =**

$$S' \to floatA'$$

$$A' \to \omega B'$$

! нет правила вывода – цепочка не распознались

c) ***Пример:*** грамматика $G = (T, N, P, S')$ для **float f;**

$$T = \{A, B,.., Z, a, b,..., z, 0, 1,...9, \omega, ;, =\}, T = \{S', A', B', C', D'\},$$

$$S' \to A'$$

$$A' \to B'; | B'\omega | B' =$$

$$B' \to B'A | ... | B'Z | B'a | ... | B'z$$

$$B' \to B'0 | ... | B'9$$

$$B' \to C'A | ... | C'Z | C'a | ... | C'z$$

$$C' \to C'\omega$$

$$C' \to float\omega$$

$\omega - пробел$ **7.**

$G = (T, N, P, S')$ - регулярная леволинейная грамматика.

8. Примеры: левосторонний вывод.

Вывод называется *левосторонним*, если в нем на каждом шаге вывода правило грамматики применяется всегда к крайнему левому нетерминальному символу в цепочке. Другими словами – на каждом шаге вывода происходит подстановка цепочки символов на основании правила грамматики, т.е. вместо крайнего левого нетерминального символа в исходной цепочке.

a) Пример: восходящий вывод (распознавание) цепочки   float f;

Вывод цепочки	Дерево восходящего разбора цепочки
$C' \to \mathit{float}\omega$ $B' \to C'f$ $A' \to B';$ $S' \to A'$	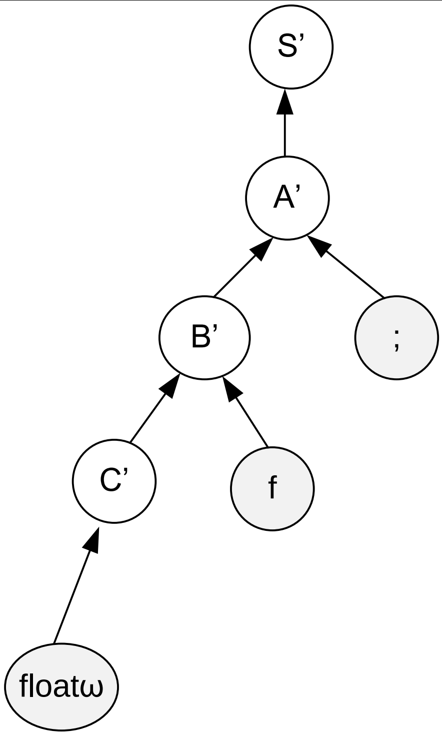

b) Пример: вывод (распознавание) цепочки float f2x =

$$C' \to \mathit{float}\omega$$
$$B' \to C'f$$
$$B' \to B'2$$
$$B' \to B'x$$
$$A' \to B'\omega;$$
$$S' \to A'$$

Восходящий вывод цепочки

9. Для описания лексики языка программирования, обычно применяются регулярные грамматики.

С точки зрения лексического анализатора – язык программирования набор лексем (токенов), которые распознаются (классифицируются) лексическим анализатором.

Язык программирования на уровне лексического анализа представляет собой ***регулярный язык*** (язык типа 3 иерархии Хомского).

10. Грамматика языка описывает множество правильных цепочек символов над заданным алфавитом.

Для описания регулярных языков используют другую форму описания – регулярные выражения.

11. Регулярное выражение

Регулярное выражение описывает множество цепочек – формальный язык. Для записи регулярного выражения используются метасимволы.

Множество цепочек описанных регулярным выражением называется **регулярным множеством** (или регулярным языком).

12. Определение.

Пусть I – алфавит.

Регулярные выражения над алфавитом I и языки, представляемые ими, рекурсивно определяются следующим образом:

1) $\varnothing$ – регулярное выражение, представляет пустое множество;
2) λ – регулярное выражение, представляет множество $\{\lambda\}$;
3) для каждого $a \in I$ символ a является регулярным выражением и представляет множество $\{a\}$;
4) если p – регулярное выражение, представляющее множество P и q – регулярное выражение, представляющее множество Q, то $p+q$, pq, $q*$ являются регулярными выражениями и представляют множества:
   a) $P \cup Q$ (объединение),
   b) PQ (конкатенация множеств),
   c) $P*$ (итерация) соответственно.
5) $pp* = p^+$

a) Символы, применяемые для описания регулярных выражений, называются **метасимволами** или **символами-джокерами**.

Джокерами являются символы: $*,^{+},+,(,),\varnothing$.

13. Примеры

a) регулярные выражения и множества описанные ими:

Регулярное выражение	Множество
a	a
a+b	a,b
a+b+c	a,b,c
a^{+}	a, aa, aaa, aaaa...
a*	λ, a, aa, aaa, aaaa,...
ab	ab
ab+cd	ab, cd
$(ab+cd)^{+}$	ab, cd, abab, abcd, cdcd, cdab, ababab, cdcdcd, abcdab, cdabcd, abcdcdcdcd, abababab,...
(ab+cd)*	λ, $(ab+cd)^{+}$
a(bc+de)	abc, ade
a(bc+de)f	abcf, adef
$ab^{+}c$	abc, abbc, abbbc, abbbbc,…
$ab^{*}c$	ac, abc, abbc, abbbc, abbbbc,…
$a(bc+de)^{+}f$	abcf, adef, abcbcf, abcdef, adebcf, adedef, abcdedcdef,...
$a(bc+de)^{*}f$	af, $a(bc+de)^{+}f$
(ab+cd)(ef+gh)	abef,abgh, cdef, cdgh
$(ab+cd)e^{+}$	abe, cde,abee, cdee, abeee, cdeee,...
$(ab+cd)e^{*}$	ab, cd, $(ab+cd)e^{+}$

b) Пример для ***float f***

$$float(\omega)^{+}(A+B+..+Z+a+b+...+z)^{+}$$

$$(A+B.+..+Z+a+b+...+z+0+1.+..+9)^{*}$$

14. Теория регулярных языков была разработана в 1940-х годах.

Нейрофизиологи **Уоррен Мак-Каллох** и **Уолтер Питс** моделировали нервную систему на нейронном уровне. Математик **Стивен Клин** формально описал модели нейрофизиологов с помощью алгебры, которую назвал регулярными множествами. Для формального описания этих множеств он разработал простую математическую запись, которую назвал регулярным языком.

Запись использует специальные символы, которые в настоящее время называют метасимволами или символами-джокерами.

15. На сегодняшний день существует несколько диалектов регулярных языков (наборов метасимволов):

grep (global regular expression print) – команда в unix/linux;
egrep (extended grep) – разработал Альфред Ахо;
BRE (Basic Regular Expression) и **ERE** (Extended regular expression) – BRE + POSIX (Portable Operating System Interface) – попытка стандартизировать;
Perl – встроенные в язык Perl регулярные выражения;
ECMA–стандарт регулярных выражений в JavaScript;
SED (Stream Editor) – Bell Labs (1973-74 Lee E. McMahon).

16. Чаще всего используется Perl-нотация (набор метасимволов) регулярных выражений (в том числе в стандартных библиотеках C++ и C#).

17. В стандартной библиотеке C++ набор функций **<regex>**.

18. Пример применения функции **regex_math**:

```
#include "stdafx.h"
#include <regex>
//std::regex_constants, std::regex_error
//std::regex_replace, std::regex_iterator
//std::regex_match, std::regex_search, std::regex_token_iterator
//std::regex_traits

int _tmain(int argc, _TCHAR* argv[])
{
    char    ch1[]   = "1234567899";
    wchar_t ch1w1[] = L"1234567899", wch2[] = L"12345X6799";
    char    ch2[]   = "ABCDEFGHIR",   ch2r[]  = "АБВГДЕЖЗИК";
    char    ch3[]   = "abcdefghir",   ch4[]   = "a1b2c3de3f";
    char    ch5[]   = "11345.2234",   ch6[]   = "11345. 223";
    char    ch7[]   = "27.01.1960";
    bool b1    = std::regex_match(ch1,   ch1+10,   std::regex("[0-9]*"));  // true
    bool b1w   = std::regex_match(ch1w1, ch1w1+10, std::regex("[0-9]*")); // true
    bool b1w1  = std::regex_match(wch2,  wch2+10,  std::regex("[0-9]*")); // false
    bool b2    = std::regex_match(ch1,  ch1+10,    std::regex("[A-Z]*"));  // false
    bool b2r   = std::regex_match(ch2r, ch2r+10,   std::regex("[А-Я]*"));  // true
    bool b3    = std::regex_match(ch2,  ch2+10,    std::regex("[A-Z]*"));  // true
    bool b4    = std::regex_match(ch2,  ch2+10,    std::regex("[a-z]*"));  // false
    bool b5    = std::regex_match(ch3,  ch3+10,    std::regex("[a-z]*"));  // true
    bool b5r   = std::regex_match(ch3,  ch3+10,    std::regex("[a-z]*"));  // true
    bool b6    = std::regex_match(ch4,  ch4+10,    std::regex("[a-z|0-9]*"));  // true
    bool b7    = std::regex_match(ch3,  ch3+10,    std::regex("[a-z|0-9]*"));  // true
    bool b8    = std::regex_match(ch2,  ch2+10,    std::regex("[a-z|0-9]*"));  // false
    bool b9    = std::regex_match(ch2,  ch2+10,    std::regex("[a-z|A-Z]*"));  // true
    bool b10   = std::regex_match(ch5,  ch5+10,    std::regex("[0-9]+.[0-9]*"));   // true
    bool b11   = std::regex_match(ch6,  ch6+10,    std::regex("[0-9]+.[0-9]*"));   // false

    #define DD   "(0[1-9]+|1[0-9]+|2[0-9]+|3[0|1]+)"
    #define MM   "(0[1-9]+|1[0-2]+)"
    #define YYYY "([0-9]{4,4})"
    bool b12   = std::regex_match(ch7,  ch7+10,  std::regex(DD "\." MM "\." YYYY)); // true

    return 0;
}
```

19. Схема работы лексического анализатора

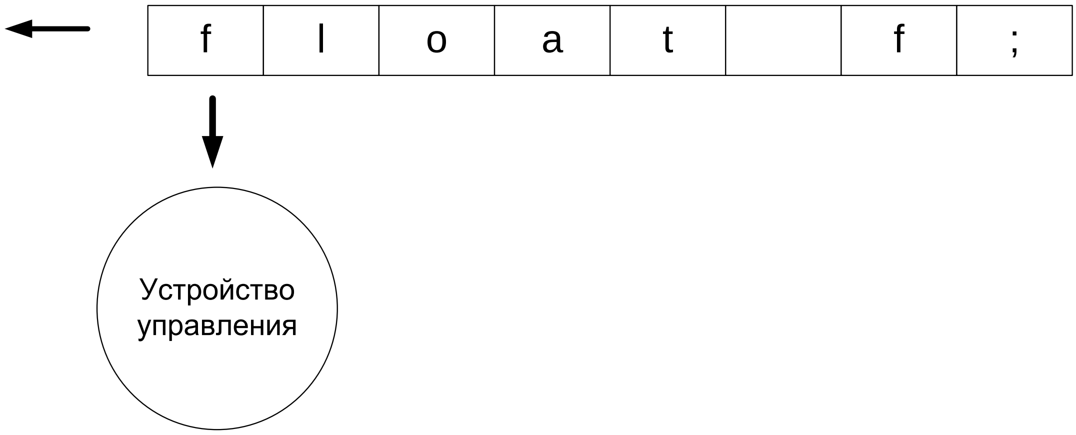

Класс алгоритмов, соответствующих приведенной выше схеме, может быть записан в форме конечного автомата (КА).

20. Определение КА:

КА это пятерка $M = (S, I, \delta, s_0, F)$,

где

S – конечное множество состояний устройства управления;

I – алфавит входных символов;

δ – функция переходов, отображающая $S \times (I \cup \{\lambda\})$ во множество подмножеств S: $\delta(s,i) \subset S, s \in S, i \in I$;

$s_0 \in S$ - начальное состояние устройства управления;

$F \subseteq S$ - множество заключительных (допускающих) состояний устройства управления.

Если $\delta(s,\lambda) = \varnothing$ и $|\delta(s,a)| \leq 1$, то конечный автомат – **детерминированный** (ДКА).

Т.е. отсутствуют состояния, имеющие λ-переходы и для каждого состояния s и входного символа a существует не более одной дуги, выходящей из s и помеченной как a. ДКА – это автомат, который переходит из любого состояния по любому символу точно в одно состояние.

Иначе - конечный автомат является **недетерминированным** (НКА).

21. Мгновенное описание КА – пара (s, w),

где $s \in S$ – состояние КА,

$w \in I^*$ – неиспользованная часть входной цепочки.

22. (s_0, w_0) – начальное мгновенное описание КА,

где w_0 – анализируемая цепочка.

23. (s_f, λ), $s_f \in S$ – допускающее мгновенное описание КА.

24. Если (s, aw) и $s' \in \delta(s, a)$, где $s', s \in S$, $a \in I \cup \lambda$, $w \in I^*$, то $(s, aw) \succ (s', w)$ – читается: непосредственно следует.

25. Если $(s_i, w_i) \succ (s_{i+1}, w_{i+1}) \succ (s_{i+2}, w_{i+2}) \succ \ldots \succ (s_k, w_k)$, то $(s_i, w_i) \succ^* (s_k, w_k)$ – следует.

26. Если $(s_0, w) \succ^* (s_f, \lambda)$, $s_0 \in S$ – начальное состояние,

$s_f \in F$ – конечное состояние,

то цепочка $w \in I^*$ допускается (или распознается) КА.

27. Пример: пусть $w \in (a+b)^* aba$ входная цепочка,

КА $M = (\{s_1, s_2, s_3, s_4\}, \{a, b\}, \delta, s_1, \{s_4\})$, где функция δ задана следующей таблицей:

	a	b	λ
s_1	$\{s_1, s_2\}$	$\{s_1\}$	$\varnothing$
s_2	$\varnothing$	$\{s_3\}$	$\varnothing$
s_3	$\{s_4\}$	$\varnothing$	$\{s_1\}$
s_4	$\varnothing$	$\varnothing$	$\{s_2\}$

28. Последовательность мгновенных описаний автомата

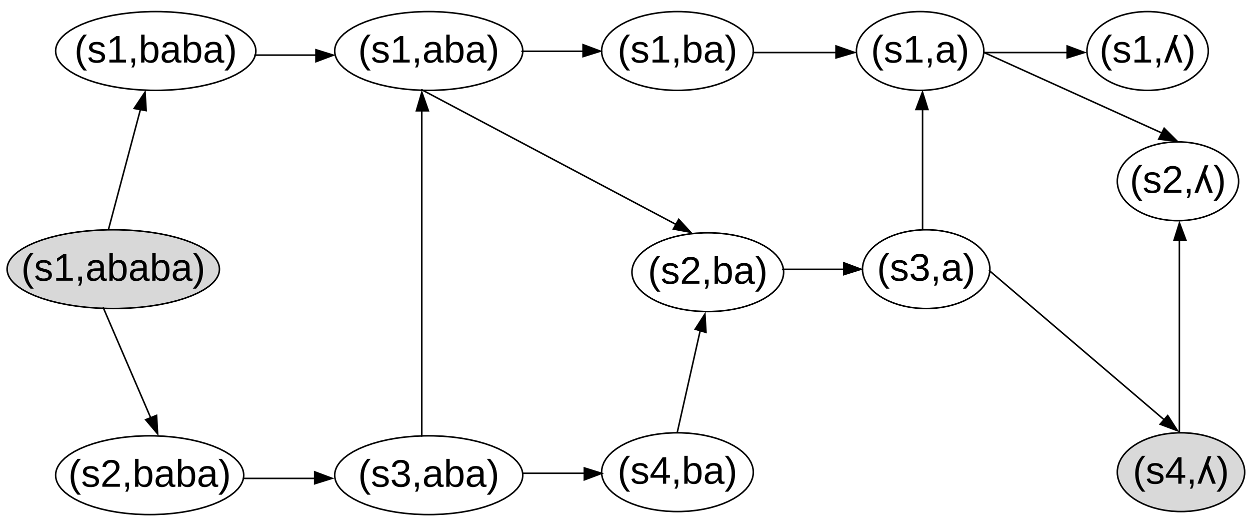

29. $(s_1, abaaba) \succ^* (s_4, \lambda)$ – значит, что автомат M допускает (распознает) цепочку $abaaba$.

30. ***Определение.***

Графом переходов конечного автомата $M = (S, I, \delta, s_0, F)$ называется ориентированный граф $G = (S, E)$,

где S - множество вершин графа совпадает с множеством состояний конечного автомата,

E – множество ребер (направленных линий, соединяющих вершины),

ребро $(s_i, s_j) \in E$, если $s_j \in \delta(s_i, a), a \in I \cup \lambda$.

Метка ребра (s_i, s_j) – все a, для которых $s_j \in \delta(s_i, a)$.

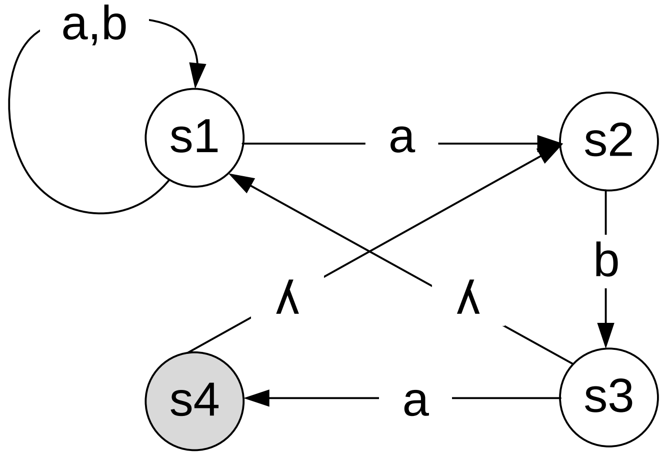

31. Конечный автомат может быть однозначно задан своим графом переходов.

32. Доказаны 4 утверждения:

1) язык является регулярным множеством тогда и только тогда, когда он задан регулярной грамматикой;
2) язык может быть задан регулярной грамматикой (левосторонней или правосторонней) тогда и только тогда, когда язык является регулярным множеством;
3) язык является регулярным множеством тогда и только тогда, когда он задан конечным автоматом;
4) язык распознается с помощью конечного автомата тогда и только тогда, когда он является регулярным множеством.

Другими словами:

любой регулярный язык может быть задан регулярной грамматикой, регулярным выражением или конечным автоматом.

Или:

любой конечный автомат задает регулярный язык, а значит грамматику или регулярное выражение.

33. Доказана теорема (А. Ахо, Дж. Хопкрофт, Дж. Ульман):

> Пусть α - регулярное выражение, тогда найдется недетерминированный конечный автомат $M = (S, I, \delta, s_0, \{s_f\})$, допускающий автомат, представленный α, и обладающий следующими свойствами:
>
> 1) $|S| \le 2|\alpha|$;
>
> 2) $\forall a \in I \cup \{\lambda\} : \delta(s_f, a) = \varnothing$;
>
> 3) $\forall s \in S : \sum\limits_{a \in I \cup \{\lambda\}} |\delta(s, a)| \le 2$.

34. Построение графа конечного автомата по регулярному выражению:

Метод построения. Автомат для выражения строится композицией из автоматов, соответствующих подвыражениям. На каждом шаге построения строящийся автомат имеет в точности одно заключительное состояние, в начальное состояние нет переходов из других состояний и нет переходов из заключительного состояния в другие.

$\varnothing$

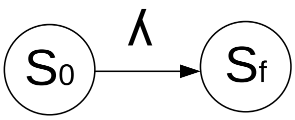

λ

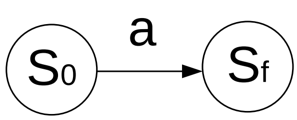

a

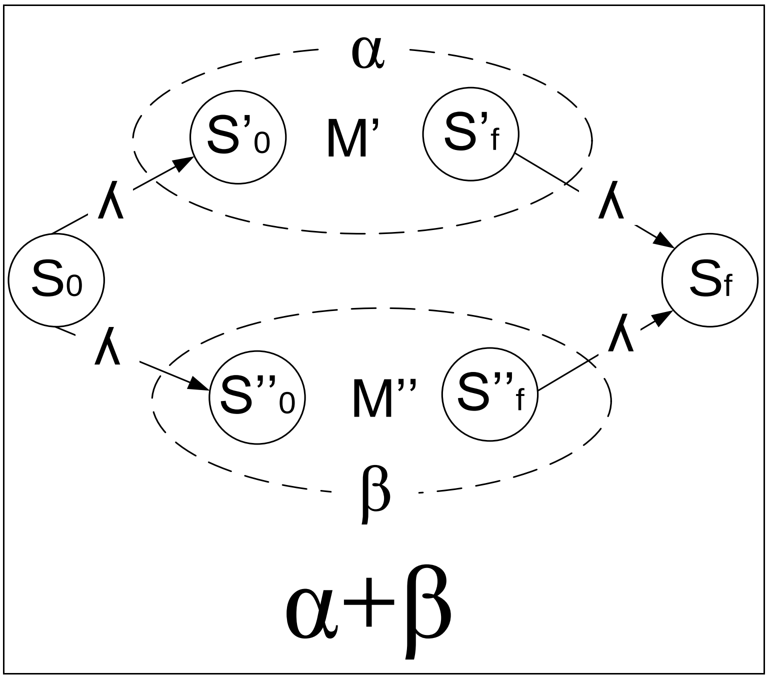
α
S'0
M'
S'f
ʎ
ʎ
S0
Sf
ʎ
ʎ
S''0
M''
S''f
β
α+β

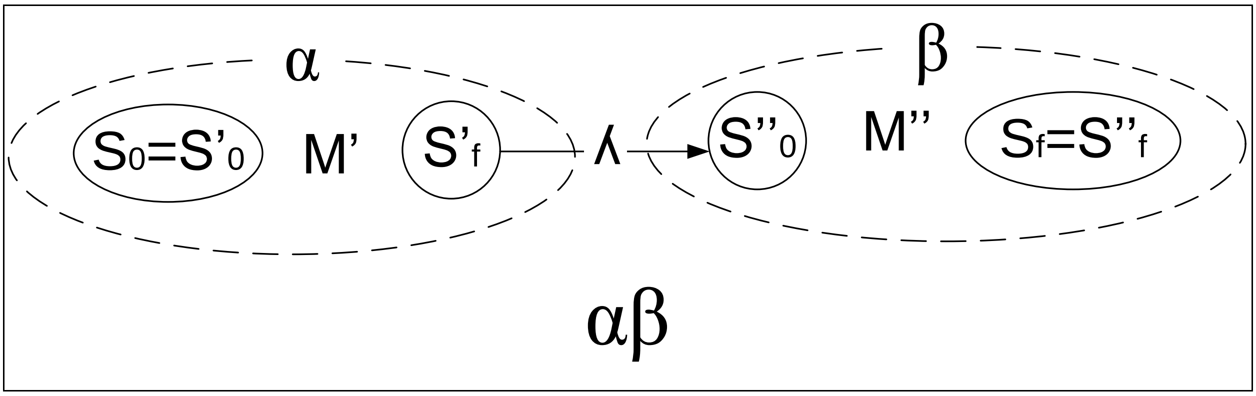
α
β
S0=S'0
M'
S'f
ʎ
S''0
M''
Sf=S''f
αβ

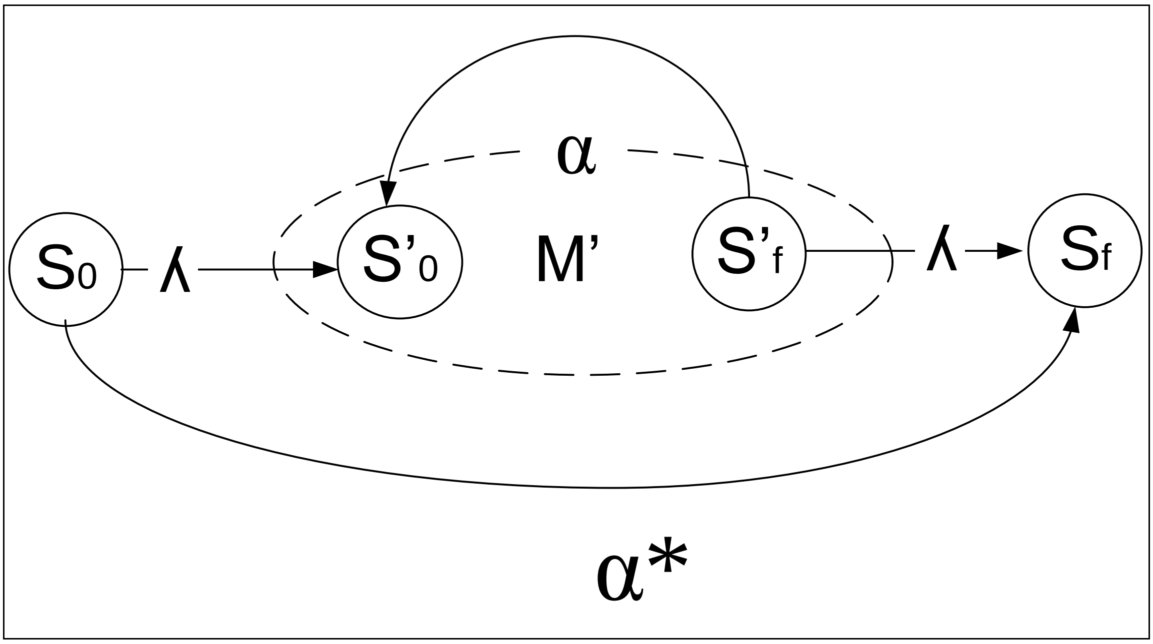
α
S0
ʎ
S'0
M'
S'f
ʎ
Sf
α*

35. ***Пример:*** пусть язык L задан регулярным выражением $(a+b)*aba$

a) Подвыражение: $a+b$

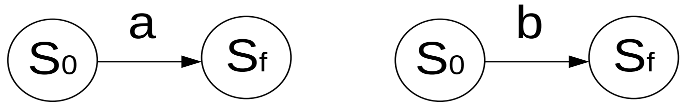

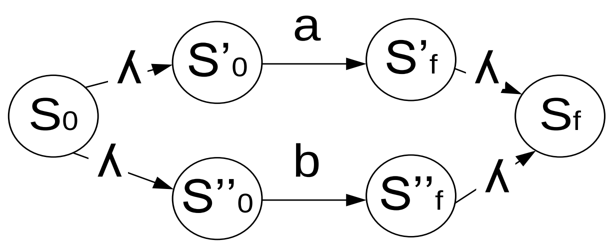

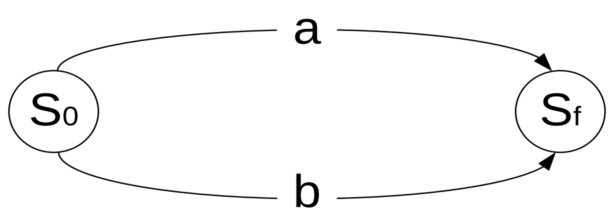

b) Подвыражение: aba

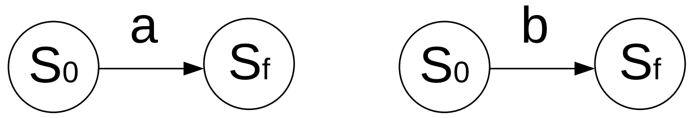

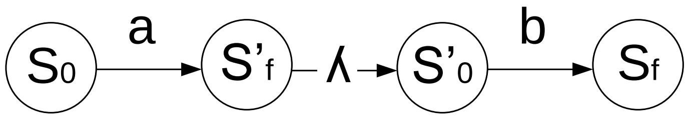

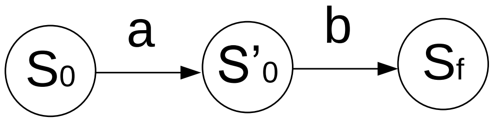

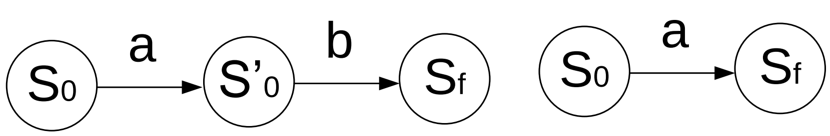

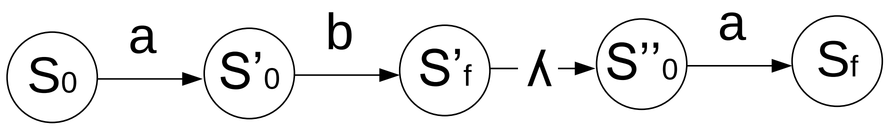

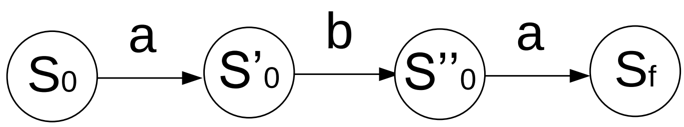

c) Продолжение. Подвыражение: $(a+b)*$

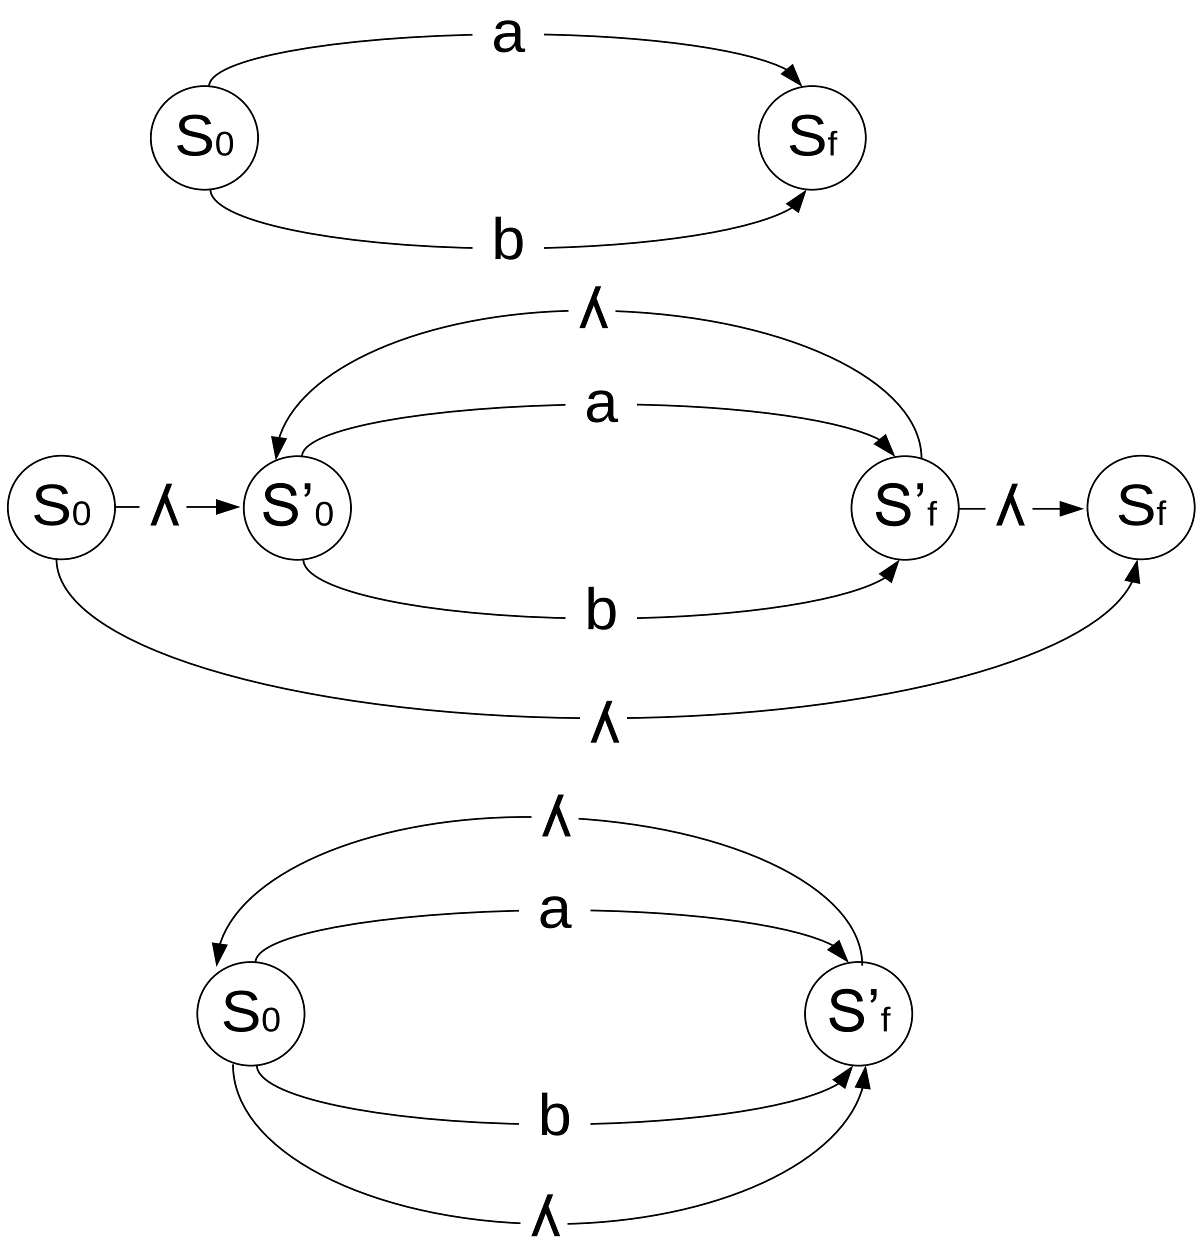

d) Выражение: $(a+b)*aba$

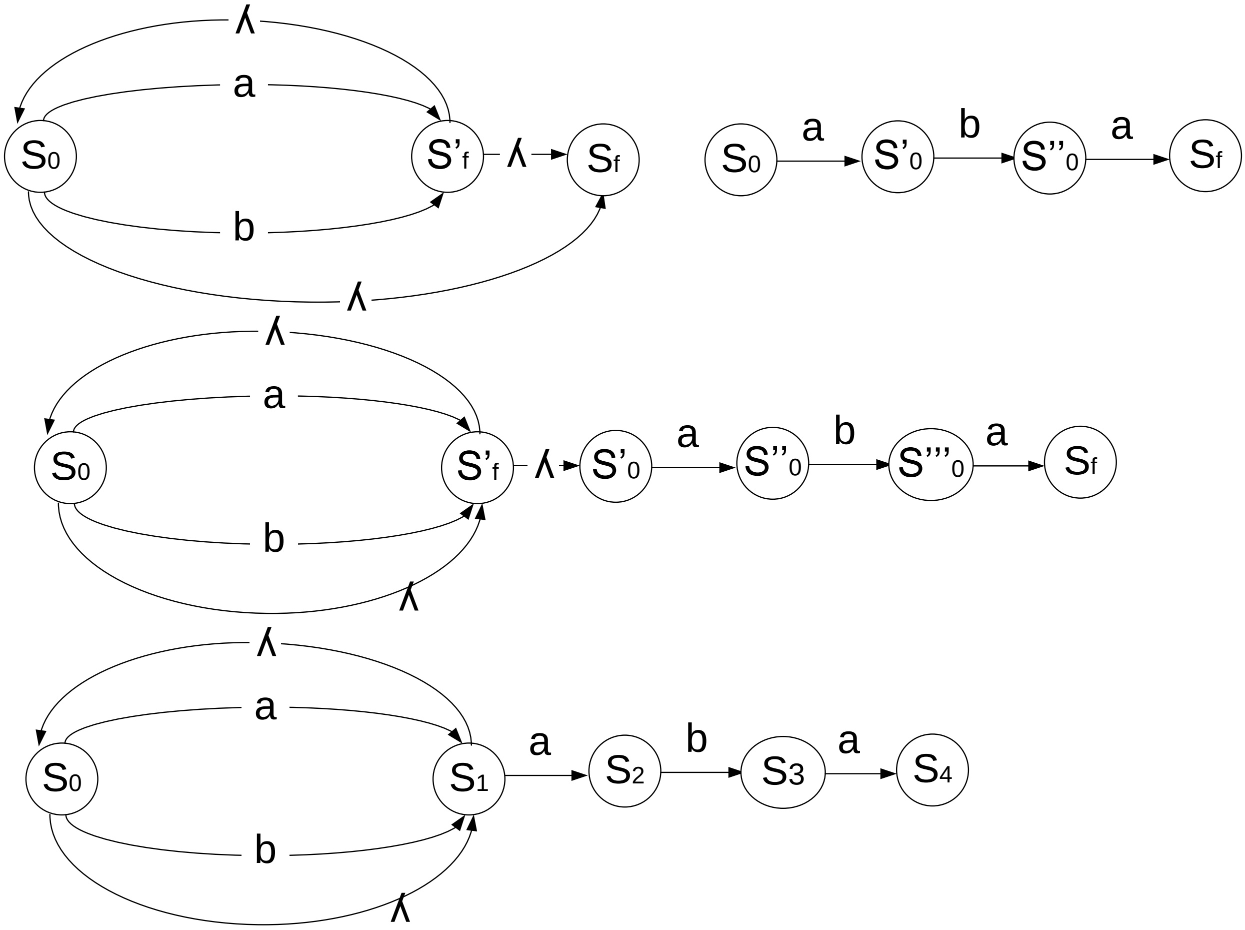

e) Пример (продолжение): $(a+b)*aba$

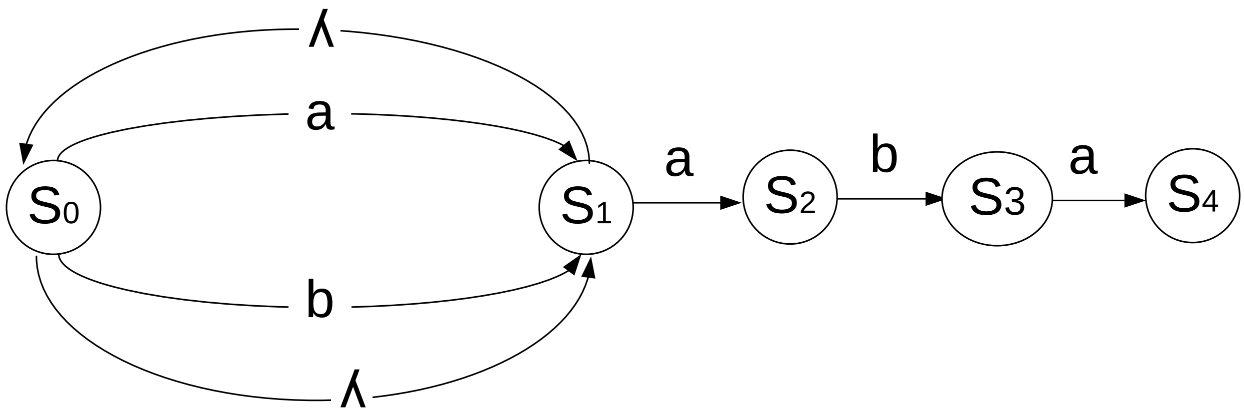

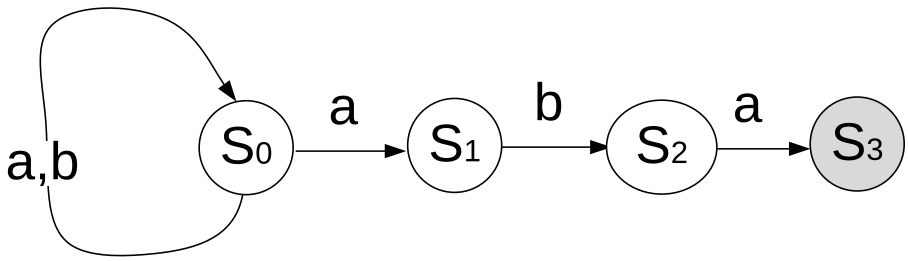

f) Пример (продолжение): $(a+b)*aba$

$$M = (\{s_0, s_0, s_2, s_3\}, \{a, b\}, \delta, s_0, \{s_3\})$$

	a	b	λ
s_0	$\{s_0, s_1\}$	$\{s_0\}$	$\varnothing$
s_1	$\varnothing$	$\{s_2\}$	$\varnothing$
s_2	$\{s_3\}$	$\varnothing$	$\varnothing$
s_3	$\varnothing$	$\varnothing$	$\varnothing$

36. Пример (продолжение): алгоритм разбора

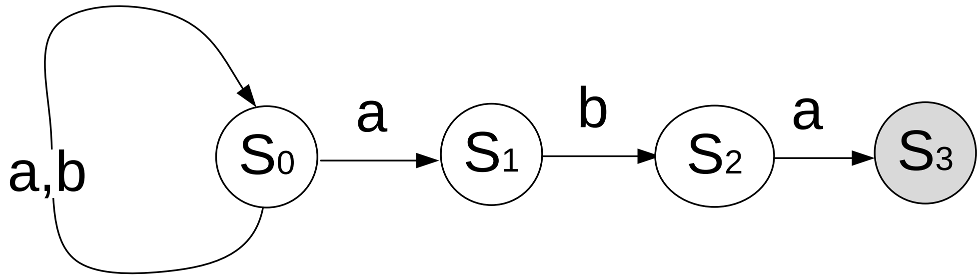

aabbabaaba	$\{S_0\}$	
abbabaaba	$\{S_0,S_1\}$	
bbabaaba	$\{S_0,S_1\}$	
babaaba	$\{S_0,S_2\}$	
abaaba	$\{S_0\}$	
baaba	$\{S_0,S_1\}$	
aaba	$\{S_0,S_2\}$	
aba	$\{S_0,S_1,S_3\}$	
ba	$\{S_0,S_1\}$	
a	$\{S_0,S_2\}$	
	$\{S_0,S_3\}$	**Успешный разбор**

37. Пример (продолжение): алгоритм разбора

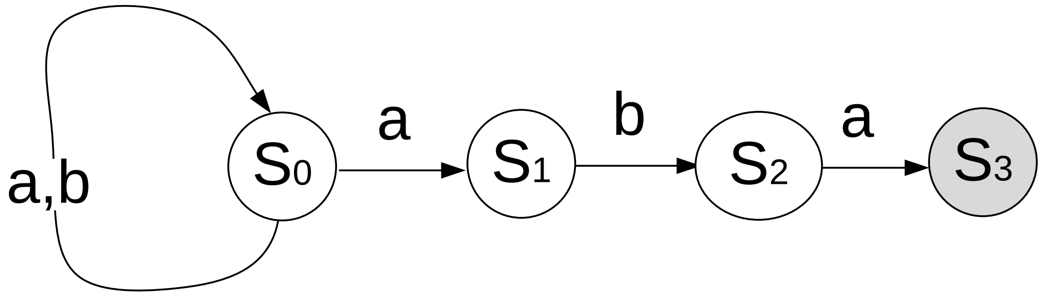

aabbababba	$\{S_0\}$	
abbababba	$\{S_0,S_1\}$	
bbababba	$\{S_0,S_1\}$	
bababba	$\{S_0,S_2\}$	
ababba	$\{S_0\}$	
babba	$\{S_0,S_1\}$	
abba	$\{S_0,S_2\}$	
bba	$\{S_0,S_1,S_3\}$	
ba	$\{S_0,S_2\}$	
a	$\{S_0\}$	
	$\boxed{\{S_0,S_1\}}$	**Ошибка разбора**

38. Пример (продолжение): алгоритм разбора

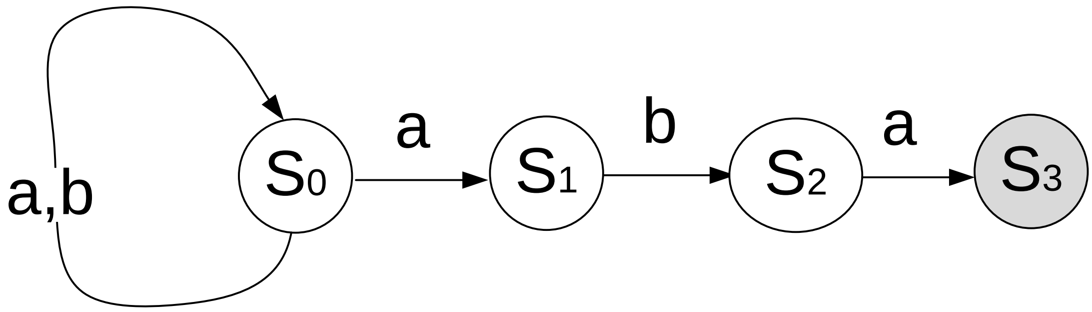

aabbxbabba	$\{S_0\}$	
abbxbabba	$\{S_0, S_1\}$	
bbxbabba	$\{S_0, S_1\}$	
bxbabba	$\{S_0, S_2\}$	
xbabba	$\{\}$	**Ошибка разбора**

39. Реализация алгоритма для разбора